MODUL PENELITIAN DAN ARSITEKTUR SISTEM

SafeMine Monitor

A Python-Based Computational Framework and Web-Based Monitoring System for Unsafe Behavior Analysis in Mining Construction

Jawaban terstruktur atas 11 poin permintaan pengembangan, kerangka metodologis Phase 1 dan Phase 2, model Evolutionary Game Theory (EGT), arsitektur teknis, dan rencana menuju Midterm Defense

Program	Master - Safety Science and Engineering
Tahap	Preliminary prototype - internal demo 19 November 2026, Midterm Defense 21 November 2026
Status dokumen	Draf untuk diskusi dengan supervisor dan tim pengembang
Tanggal	12 November 2026
Lampiran	Folder kode SafeMine_Monitor (backend, frontend, model, skrip, data template, dokumentasi)

DAFTAR ISI

0. Ringkasan Eksekutif 3
1. Research Background and Main Objective 4
2. Proposed Research Title and System Name 5
3. Research Framework: Phase 1 and Phase 2 5
4. Target Users 8
5. Main Features and Functional Requirements 8
6. Safety Indicators and Scientific References 9
7. Data Characteristics and System Operation 11
8. Technical Architecture and Integration 12
9. Development Priority and Midterm Defense Target 17
10. Expected Deliverables from the Development Team 18
11. Important Questions for the Team - Jawaban 19
12. Keterbatasan dan Pernyataan Kejujuran Ilmiah 20
Referensi 20

0. Ringkasan Eksekutif

Modul ini menjawab seluruh 11 poin dalam dokumen permintaan pengembangan dan menerjemahkannya menjadi sistem yang sudah dikodekan (folder *SafeMine_Monitor*). Prinsip utamanya: website bukan dashboard yang berdiri sendiri, melainkan lapisan presentasi dari dua komponen penelitian yang benar-benar dijalankan oleh Python, yaitu (1) analisis komputasional dan pemodelan perilaku dengan EGT (Phase 1) dan (2) identifikasi unsafe behavior berbasis computer vision (Phase 2).

Alur inti yang sudah diimplementasikan dalam kode:

Upload Video/Gambar → Python Processing (OpenCV) → Computer Vision Detection (YOLO11 + ByteTrack) → Identifikasi Unsafe Behavior (rule engine) → Event Bertimestamp → Klasifikasi Risiko HIRARC → Database → Web Monitoring

Jawaban atas keterbatasan utama (tidak ada sensor/kamera live, hanya upload). Keterbatasan ini dapat diatasi secara metodologis maupun teknis. Secara teknis, setiap video yang diunggah diperlakukan sebagai *virtual camera*: selama dianalisis, frame beranotasi dialirkan ke browser (MJPEG stream) lengkap dengan ID pekerja, panel status APD per pekerja, dan penghitung event, sehingga tampilan monitoring identik dengan feed CCTV - namun diberi label jujur **REPLAY**. Hasil tersimpan dengan timestamp waktu-video. Secara metodologis, video unggahan justru lebih kuat untuk tesis karena eksperimen dapat diulang (reproducible) dan dapat dibandingkan dengan ground truth yang dilabeli manual, sesuatu yang sulit dilakukan pada feed live. Sumber video diambil oleh satu fungsi *cv2.VideoCapture*, sehingga webcam atau URL RTSP CCTV dapat disambungkan kelak tanpa mengubah pipeline (future work). Detail di Bagian 7.

Status jujur pada saat modul ini disusun: kode backend, frontend, rule engine, risk module, analytics, EGT, dan validasi sudah lengkap dan lolos unit test (8/8 test, termasuk uji end-to-end pipeline video dengan detektor tiruan). Yang masih harus dilakukan developer dalam 3 hari: melatih model APD (best.pt) di GPU cloud, mengumpulkan/merekam video uji, menjalankan validasi, dan mengganti data riset sintetis dengan data riil (lihat PDF Panduan Developer 3 Hari).

1. Research Background and Main Objective

Perilaku tidak aman (unsafe behavior) merupakan penyebab langsung mayoritas kecelakaan konstruksi; literatur yang dirangkum Bonyaniakbarabadi (2025) menyebut kisaran 70-88% kecelakaan konstruksi berkaitan dengan perilaku tidak aman pekerja. Pemantauan manual (inspeksi, checklist BBS) bersifat sampling, lambat, dan subjektif. Computer vision menawarkan pengamatan kontinu dan objektif (Tang, 2021; Alotaibi dan Ma, 2025), tetapi deteksi saja tidak menjelaskan *mengapa* perilaku tidak aman bertahan di organisasi. Di sinilah Evolutionary Game Theory relevan: EGT memodelkan bagaimana keputusan pekerja, supervisor, dan manajemen saling memengaruhi dan berevolusi dari waktu ke waktu.

Tujuan umum: mengembangkan framework komputasional berbasis Python yang menganalisis, mengidentifikasi, dan membantu memonitor unsafe behavior dalam konstruksi pertambangan melalui computational analysis, behavioral modeling (EGT), dan intelligent visual recognition, yang diimplementasikan sebagai preliminary web-based monitoring system.

Usulan research questions (untuk disesuaikan dengan Opening Report):

1. RQ1 (Phase 1): Pola dan indikator risiko perilaku tidak aman apa yang dapat diekstraksi dari data keselamatan pertambangan melalui analisis Python?
2. RQ2 (Phase 1): Bagaimana interaksi strategis pekerja-supervisor-manajemen memengaruhi evolusi perilaku keselamatan, dan bagaimana efek teknologi pemantauan visual terhadap kestabilan strategi tersebut?
3. RQ3 (Phase 2): Sejauh mana model computer vision dapat mengidentifikasi kategori unsafe behavior terpilih dari gambar/video konstruksi pertambangan (precision, recall, F1)?
4. RQ4 (Implementasi): Bagaimana hasil Phase 1 dan Phase 2 dapat diintegrasikan dalam satu platform monitoring dan penilaian risiko berbasis web?

Dua kontribusi yang saling terhubung: (1) *Research contribution* - pendekatan analisis dan pemodelan unsafe behavior dengan Python dan EGT tripartit yang dikalibrasi oleh data visual; (2) *Practical implementation* - prototipe SafeMine Monitor yang mendemonstrasikan identifikasi unsafe behavior dengan computer vision yang benar-benar berjalan. Website adalah implementasi yang mendukung framework, bukan pengganti metodologi.



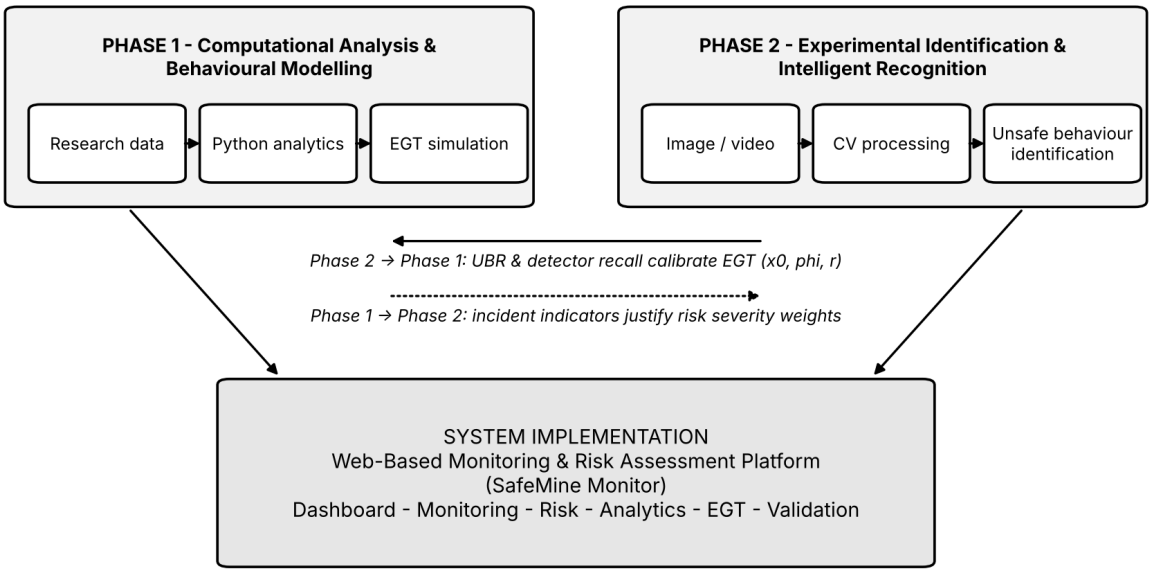
Gambar 1. Alur demonstrasi utama yang diimplementasikan (Priority 1).

2. Proposed Research Title and System Name

Elemen	**Usulan**
Judul penelitian (versi pengguna)	A Python-Based Computational Framework and Web-Based Monitoring System for Unsafe Behavior Analysis in Mining Construction
Alternatif yang menonjolkan EGT dan CV	A Python-Based Computational Framework Integrating Evolutionary Game Theory and Vision-Enabled Web Monitoring for Unsafe Behavior Analysis in Mining Construction
Nama sistem	SafeMine Monitor
Deskripsi sistem	A Python-Based Computational and Vision-Enabled Web Monitoring System for Unsafe Behavior Analysis in Mining Construction

Catatan: judul versi pengguna tidak menyebut EGT maupun computer vision, padahal keduanya adalah inti metodologi. Jika supervisor menginginkan judul ringkas, EGT dan CV cukup muncul di abstrak dan research objectives; jika ingin eksplisit, gunakan versi alternatif. Keduanya konsisten dengan Opening Report karena kerangka dua fase tidak berubah.

3. Research Framework: Phase 1 and Phase 2



Gambar 2. Kerangka penelitian dua fase dan hubungan metodologisnya dengan platform web.

3.1 Phase 1 - Computational Analysis and Behavioral Modeling

Komponen (brief)	**Implementasi dalam kode**	**Output**
Data preprocessing and management	analytics.preprocess(): validasi skema, deduplikasi, parsing tanggal, imputasi severity, tagging naratif berbasis kata kunci	Laporan kualitas data
Exploratory Data Analysis	Distribusi kategori, Pareto, tren bulanan, distribusi severity, per okupasi dan shift	Grafik di halaman Analytics
Identifikasi pola unsafe behavior	Pareto + uji chi-square (pengalaman × kategori) dengan Cramer's V	Pola signifikan
Ekstraksi behavioral risk indicators	BRI per kategori, Unsafe Behaviour Rate (UBR), compliance rate, events/menit, exposure ratio	Indikator kuantitatif
Statistical and risk analytics	pandas, NumPy, SciPy; risiko HIRARC	Tabel indikator
EGT modeling and simulation	egt.py: game tripartit, replicator dynamics, RK4, Jacobian, sensitivity	Trajektori, ESS, sensitivitas
Interaksi pekerja-super visor-manajemen	Payoff per profil strategi murni (8 profil) ditampilkan transparan	Payoff matrix

3.2 Phase 2 - Experimental Identification and Intelligent Recognition

Komponen (brief)	Implementasi dalam kode	Output
Image/video acquisition	Upload, sample library (virtual camera), eksperimen rekaman terkontrol	Media uji
Identifikasi kategori unsafe behavior	rules.py: NO_HELMET, NO_VEST, RESTRICTED_ZONE, MACHINE_PROXIMITY	Status per pekerja
Computer vision recognition	detector.py: YOLO11 (model APD kustom) + ByteTrack untuk ID pekerja	Bounding box, label, confidence
Visual detection and classification	pipeline.py: anotasi frame, snapshot bukti, video beranotasi	Media beranotasi
Preliminary experimental observation	Event temporal (start, end, durasi, exposure), filter persistensi 0,5 s	Event bertimestamp
Evaluation of detection results	Model-level (P, R, mAP) dan event-level (P, R, F1 vs ground truth)	Metrik validasi

3.3 Hubungan metodologis Phase 1 dan Phase 2

Hubungan kedua fase tidak sekadar ditampilkan berdampingan, tetapi dihubungkan oleh tiga jembatan yang dapat dipertanggungjawabkan:

1. **Phase 2 → Phase 1 (kalibrasi kondisi awal):** proporsi awal pekerja yang berperilaku aman dalam EGT ditetapkan $x_0 = 1 - UBR$, dengan UBR (Unsafe Behaviour Rate) diukur langsung oleh sistem visi pada video uji.
2. **Phase 2 → Phase 1 (parameter teknologi):** recall detektor r (hasil validasi) dan cakupan kamera φ masuk ke probabilitas deteksi dalam EGT: $\alpha_I = 1 - (1 - \alpha_0)(1 - \varphi r)$ dan $\beta_I = 1 - (1 - \beta_0)(1 - \varphi r)$. Dengan demikian simulasi menjawab pertanyaan: *apa dampak sistem pemantauan visual dengan kualitas tertentu terhadap evolusi perilaku keselamatan?*
3. **Phase 1 → Phase 2 (dasar penilaian risiko):** statistik insiden (mean severity, proporsi fatal per kategori, BRI) menjadi dasar empiris bobot severity S pada matriks risiko HIRARC yang digunakan untuk mengklasifikasikan event hasil deteksi.

Integrasi bertahap: pada Midterm ketiga jembatan sudah berjalan di kode (tombol *Use calibration from CV data* di halaman EGT). Setelah Midterm, kalibrasi diperkuat dengan data riil dan survei ahli.

4. Target Users

Pengguna	Kebutuhan utama	Halaman yang relevan
Safety Engineer / HSE Officer	Bukti pelanggaran, tingkat risiko, rekomendasi pengendalian, tren	Dashboard, Risk Assessment, Analytics
Site Safety Supervisor	Siapa melanggar apa, kapan, di lokasi mana; tindak lanjut cepat	Monitoring (panel per pekerja), Detection Records
Project Manager	Ringkasan risiko dan kepatuhan, dampak kebijakan (insentif, penalti, investasi)	Dashboard, EGT Simulation
Safety Monitoring Personnel	Mengunggah video, memproses, memverifikasi hasil	Upload & Detect, Validation

5. Main Features and Functional Requirements

Status: **Implemented** = kode selesai dan teruji; **Ready after model** = kode selesai, butuh best.pt; **Future** = pengembangan setelah Midterm.

Modul	Fitur	Status
A. Dashboard	Total unsafe behavior, distribusi kategori, statistik level risiko, recent detections dengan snapshot, monitoring history, UBR dan helmet compliance	Implemented
B. Image & Video Input	Upload file, pilih sample video, pratinjau frame pertama, gambar poligon zona terlarang, submit, status/progress	Implemented
C. CV Detection	Bounding box, label, confidence, ID pekerja (tracking), timestamp event, video beranotasi, replay, panel APD per pekerja	Implemented; kategori APD ready after model
D. Risk Assessment	L × S HIRARC, level, rekomendasi berbasis hierarchy of controls, matriks risiko, catatan risiko	Implemented
E. Python Analytics	Preprocessing, EDA, Pareto, chi-square, tren, BRI, indikator dari sistem visi, unggah CSV riset	Implemented (data riil diperlukan)
F. EGT Simulation	Parameter, skenario, dinamika evolusi, stabilitas ekuilibrium, payoff matrix, sensitivitas, kalibrasi dari CV	Implemented (parameter perlu justifikasi)
Validation	Upload ground truth, precision/recall/F1 per kategori, metrik model	Implemented

Modul	Fitur	Status
Real-time camera	Webcam/RTSP sebagai sumber	Future

Kebutuhan non-fungsional: berjalan di laptop tanpa GPU (CPU, 3-10 fps untuk YOLO11n/s pada 640 px dengan stride 2); seluruh ambang batas di satu file konfigurasi (config.py) agar dapat dilaporkan; data tersimpan lokal (SQLite) demi privasi; setiap kategori yang tidak didukung model dinonaktifkan otomatis dan ditampilkan di sidebar sehingga sistem tidak pernah mengklaim kemampuan yang tidak dimiliki.

6. Safety Indicators and Scientific References

ISO 45001:2018 adalah standar sistem manajemen K3, bukan daftar kategori yang dapat dideteksi kamera. Karena itu dasar yang dipakai berlapis: ISO 45001 (klausul 6.1.2 identifikasi bahaya dan penilaian risiko; klausul 8.1.2 hierarchy of controls) memberi kerangka manajemen; HIRARC (DOSH Malaysia, 2008) memberi metode penilaian risiko semi-kuantitatif; regulasi tambang dan literatur memberi kategori perilaku; ketersediaan data dan kemampuan model menentukan kategori final.

6.1 Kategori unsafe behavior dan kelayakan deteksi

Kategori (brief)	Operasionalisasi visual	Dasar	Status Midterm
Improper use of PPE	NO_HELMET, NO_VEST (kelas NO-Hardhat, NO-Safety Vest)	Tang (2021); Alotaibi dan Ma (2025); ILO opencast mines CoP; GB 16423-2020	Dideteksi (perlu best.pt)
Entry into restricted / hazardous area	Titik kaki pekerja di dalam poligon zona	Bonyaniakbarabadi (2025); praktik exclusion zone	Dideteksi
Unsafe interaction with machinery	Jarak titik kaki ke kotak alat berat / tinggi badan < 1,0	Statistik MSHA (powered haulage); Tang (2021) prediksi lintasan	Dideteksi (heuristik)
Unsafe operation	Butuh action recognition berbasis urutan frame	Alotaibi dan Ma (2025) LR-BehaviorNet; dataset CMA	Future work
Unsafe movement / working practices	Butuh pose estimation / action recognition	Dataset CMA; Tang (2021)	Future work

6.2 Metode klasifikasi risiko (dasar penilaian eksplisit)

Risiko = Likelihood (L, 1-5) × Severity (S, 1-5) dengan banding HIRARC 2008: 1-4 Low, 5-12 Medium, 15-25 High. **Severity** melekat pada bahaya (bukan pada video) dan ditetapkan dari akibat terburuk yang kredibel bagi satu pekerja menurut skala HIRARC: NO_HELMET = 3 (Serious), NO_VEST = 3, RESTRICTED_ZONE = 4 (Fatal), MACHINE_PROXIMITY = 4. **Likelihood** dioperasionalkan dari data pengamatan, yaitu exposure ratio E = durasi pelanggaran ÷ durasi pekerja terlihat: E < 0,10 → 1; < 0,25 → 2; < 0,50 → 3; < 0,75 → 4; selebihnya 5; ditambah 1 jika pekerja yang sama mengulang ≥ 3 kali (habitual). Dengan demikian skor tidak dibuat sembarangan: S berasal dari literatur/statistik insiden, L dari data terukur. Nilai S perlu dikonfirmasi melalui rating ahli (misalnya 3-5 praktisi HSE) dan dibandingkan dengan mean severity hasil Phase 1.

L \ S	**1**	**2**	**3**	**4**	**5**
5	5 M	10 M	15 H	20 H	25 H
4	4 L	8 M	12 M	16 H	20 H
3	3 L	6 M	9 M	12 M	15 H
2	2 L	4 L	6 M	8 M	10 M
1	1 L	2 L	3 L	4 L	5 M

Tabel 1. Matriks risiko HIRARC (L = Low, M = Medium, H = High).

6.3 Referensi awal yang direkomendasikan

- ISO 45001:2018 (di Tiongkok diadopsi sebagai GB/T 45001-2020) - kerangka manajemen K3 dan hierarchy of controls.
- ILO-OSH 2001 Guidelines on OSH management systems; ILO Code of Practice on Safety and Health in Opencast Mines (2018).
- GB 16423-2020 Metal and Non-metal Mine Safety Regulations (relevan untuk konteks Tiongkok).
- DOSH Malaysia (2008) Guidelines for HIRARC - metode L × S.
- MSHA Accident Injuries Data Set (Form 7000-1) - data insiden tambang publik sejak tahun 2000.
- Tang (2021), Alotaibi dan Ma (2025), Bonyaniakbarabadi (2025) - referensi computer vision yang Anda lampirkan.

7. Data Characteristics and System Operation

7.1 Mengatasi keterbatasan: tanpa sensor live, hanya upload

Masalah	**Solusi dalam SafeMine Monitor**
Tidak ada feed kamera live	Mode **Replay Monitoring**: video unggahan diproses frame demi frame dan dialirkan ke browser sebagai stream MJPEG beranotasi; ada label REPLAY, timer waktu-video, panel status APD per pekerja yang diperbarui tiap detik, dan penghitung event.
Tidak ada lokasi kamera	**Virtual camera**: setiap input diberi label kamera/lokasi (misal CAM-01 Open-Pit Haul Road) sehingga riwayat monitoring tersusun seperti jaringan CCTV.
Tidak ada data lapangan tambang	Tiga lapis data: (1) dataset publik berlabel untuk melatih dan menguji model; (2) **eksperimen terkontrol** yang direkam sendiri (ground truth diketahui); (3) klip publik berlisensi terbuka untuk demonstrasi kualitatif.
Validasi tanpa sensor	Ground truth dilabeli manual per interval waktu; event-level precision/recall/F1 dihitung otomatis (temporal IoU ≥ 0,3).
Hasil harus dinamis	Semua angka di dashboard dihitung dari database hasil pemrosesan; tidak ada angka statis.
Ingin real-time kelak	Sumber video = satu fungsi cv2.VideoCapture; ganti path file dengan 0 (webcam) atau URL RTSP. Ini future work, tidak diklaim berfungsi pada Midterm.

Mengapa ini sah secara akademis: mayoritas penelitian computer vision keselamatan konstruksi melakukan evaluasi offline pada video/gambar rekaman (misalnya dataset CMA dan SODA dalam referensi Anda). Real-time hanyalah mode operasi; validitas ilmiah ditentukan oleh kualitas data uji dan ground truth, bukan oleh live streaming.

7.2 Sumber data

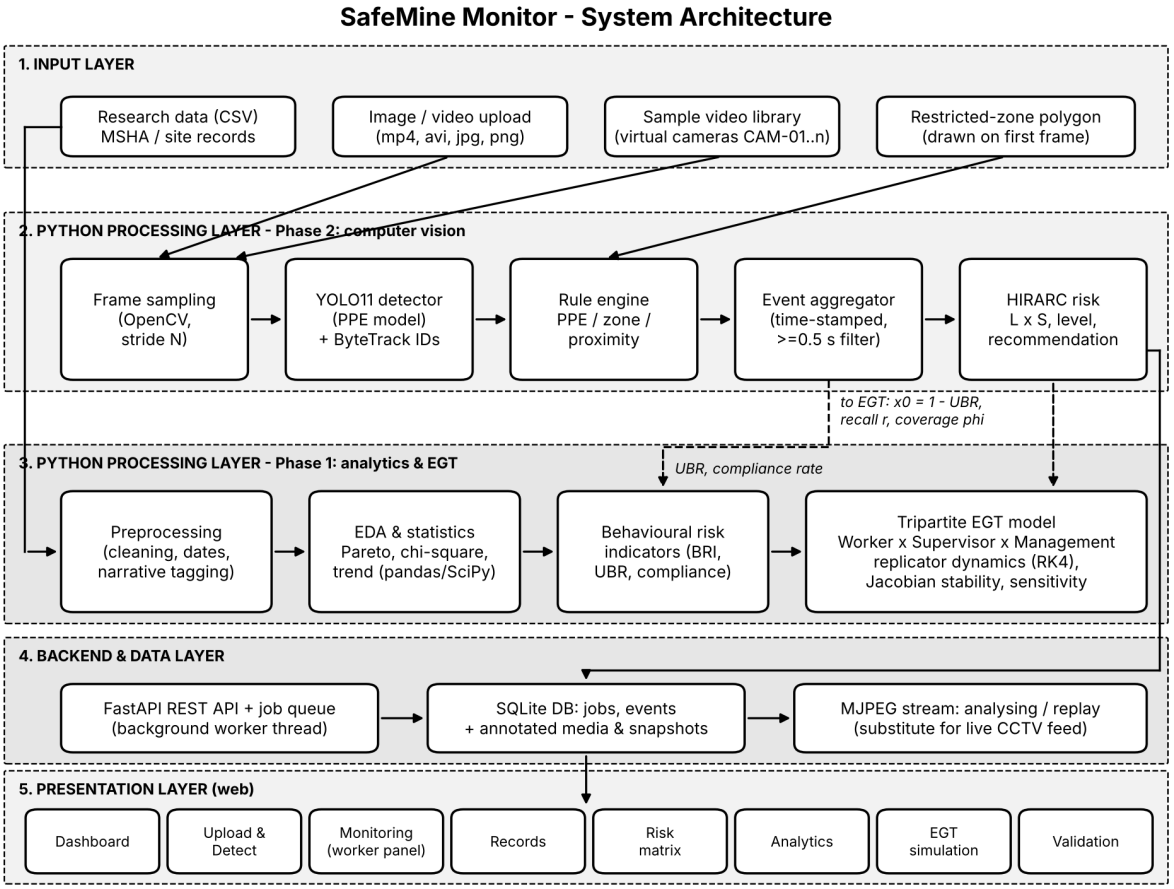
Jenis data	Sumber yang direkomendasikan	Kegunaan
Gambar berlabel APD	Roboflow Universe - Construction Site Safety (CC BY 4.0; kelas Hardhat, NO-Hardhat, Safety Vest, NO-Safety Vest, Person, machinery, vehicle). Digunakan juga oleh Alotaibi dan Ma (2025).	Training dan uji model (Phase 2)
Video eksperimen terkontrol	Rekaman sendiri: 2-4 orang, skenario helm/rompi lepas-pakai, masuk zona yang ditandai lakban, mendekati kendaraan diam. 6-10 klip @ 30-60 detik.	Validasi event-level (ground truth pasti)
Klip konstruksi/tambang publik	Video berlisensi terbuka (mis. Pexels/Pixabay/Wikimedia Commons); catat URL dan lisensi di data/samples/sources.csv	Demonstrasi kualitatif
Data insiden (Phase 1)	MSHA Accident Injuries Data Set (publik, 2000-sekarang), atau catatan K3 lokasi bila tersedia	EDA, BRI, dasar severity
Parameter EGT	Literatur EGT keselamatan + survei/expert judgment singkat	Justifikasi parameter

7.3 Operasi sistem (6 langkah dari brief)

1. User mengunggah gambar/video atau memilih sample, dan (opsional) menggambar zona terlarang di frame pertama.
2. Backend FastAPI menyimpan file, membuat job di database, dan memasukkannya ke antrean.
3. Worker Python membaca frame (OpenCV), menjalankan YOLO11 + ByteTrack, lalu rule engine.
4. Sistem mengidentifikasi kategori yang didukung model; pelanggaran ≥ 0,5 s menjadi event bertimestamp dengan snapshot bukti.
5. Event dinilai risikonya (HIRARC) dan disimpan; hasil dikirim ke web melalui REST API dan MJPEG stream.
6. Website menampilkan hasil deteksi, panel per pekerja, informasi risiko, rekomendasi, dan monitoring records.

Etika dan privasi: rekaman eksperimen memerlukan persetujuan peserta; wajah dapat diburamkan sebelum publikasi; data disimpan lokal.

8. Technical Architecture and Integration



Gambar 3. Arsitektur sistem SafeMine Monitor (lima lapis).

8.1 Teknologi yang dipilih

Lapisan	Teknologi	Alasan
Frontend	HTML, CSS, JavaScript vanilla, Chart.js	Tanpa build tool; cepat dikembangkan dalam 3 hari
Backend	FastAPI + Uvicorn (Python)	Python dan CV berada di proses yang sama; API terdokumentasi otomatis (/docs)
CV model	Ultralytics YOLO11 (n/s) fine-tuned APD + ByteTrack	Akurat, ringan untuk CPU, training mudah; tracking memberi ID pekerja
Python processing	OpenCV, NumPy, pandas, SciPy	Standar riset; hasil dapat direproduksi
Database	SQLite	Tanpa server; cukup untuk prototipe
EGT	NumPy, Runge-Kutta orde 4 implementasi sendiri	Transparan; persamaan dapat ditulis ulang di tesis
Visualisasi tesis	Matplotlib (gambar 300 dpi hitam-putih)	Siap dimasukkan ke dokumen tesis

8.2 Bukti bahwa Python benar-benar menjadi mesin komputasi

Setiap angka di website berasal dari fungsi Python yang dipanggil oleh endpoint API: /api/upload memicu pipeline CV; /api/dashboard dan /api/risk mengagregasi event di database; /api/analytics menjalankan pandas/SciPy pada data riset dan catatan deteksi; /api/egt/simulate mengintegrasikan persamaan replicator secara numerik pada setiap klik; /api/validation menghitung metrik dari ground truth. Tidak ada grafik yang dibuat terpisah lalu ditempel.

Endpoint	**Fungsi**
POST /api/upload, /api/samples/process	Menerima media, membuat job, memicu pipeline CV
GET /api/jobs/{id}, /stream, /replay, /events	Status, MJPEG analisis/replay, daftar event
GET /api/dashboard, /api/risk	Agregasi statistik dan matriks risiko
GET /api/analytics, POST /api/analytics/upload	Analisis Phase 1; unggah CSV riset
GET /api/egt/defaults, POST /api/egt/simulate	Parameter, kalibrasi dari CV, simulasi
POST /api/validation/{id}, GET /api/validation	Evaluasi terhadap ground truth
GET /api/model	Model aktif dan kategori yang didukung

8.3 Model EGT tripartit (spesifikasi matematis)

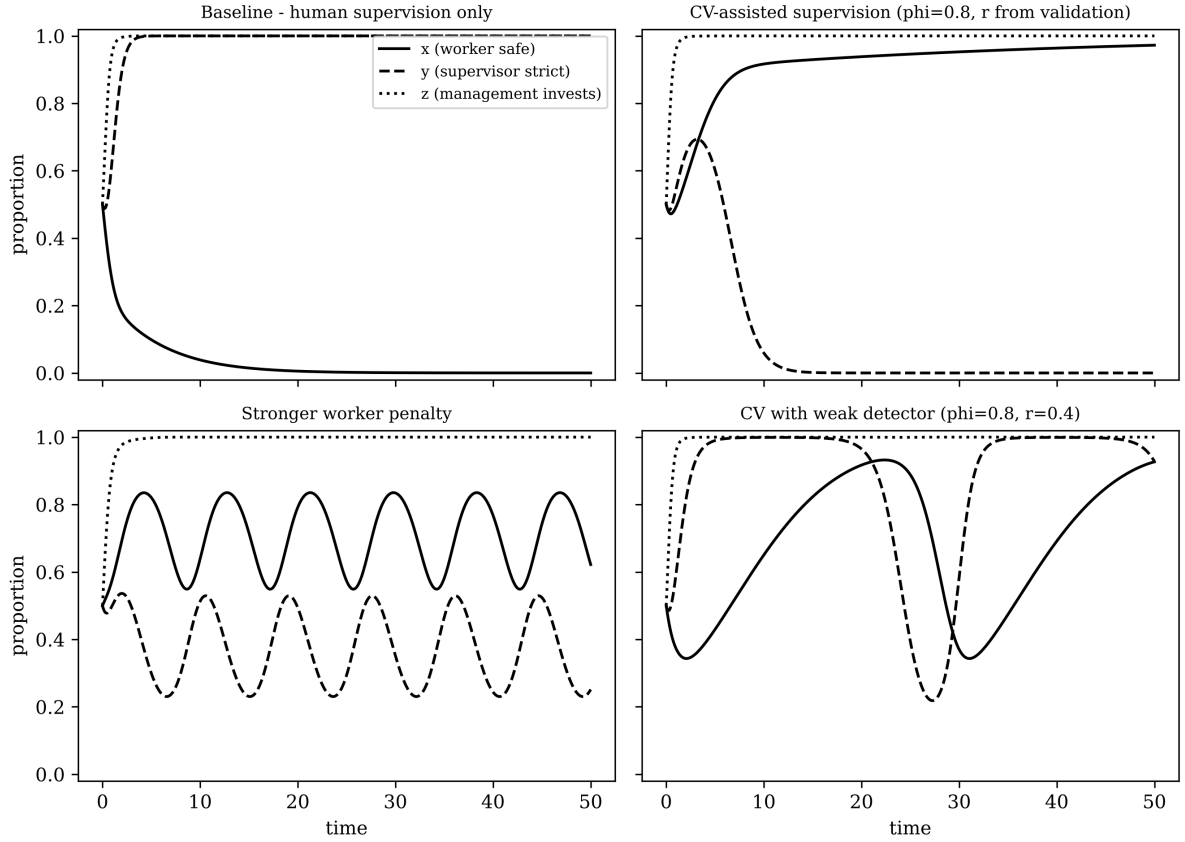
Pemain dan strategi: Pekerja (W) - Safe dengan proporsi x atau Unsafe; Supervisor (S) - Strict dengan proporsi y atau Lax; Manajemen (M) - Invest (pelatihan, insentif, sistem pemantauan visual) dengan proporsi z atau Not invest. Untuk setiap profil strategi murni (w, s, m) dengan w, s, m bernilai 0 atau 1 (1 = Safe/Strict/Invest), probabilitas tindakan tidak aman terdeteksi adalah $D = \alpha_0$ (strict) atau β_0 (lax) tanpa investasi, dan α_I, β_I dengan investasi. Probabilitas kecelakaan akibat tindakan tidak aman yang tidak terkoreksi: $A = \pi(1 - D)(1 - \eta m)$ bila $w = 0$, dan 0 bila $w = 1$.

Pemain	**Payoff strategi 1**	**Payoff strategi 0**
Pekerja	Safe: $-C_w + mR_w$	Unsafe: $B_w - DF_w - AL_w$
Supervisor	Strict: $-C_s + mR_s - AL_s$	Lax: $-AL_s - m(1 - w)F_s$
Manajemen	Invest: $-C_m + G - wR_w - sR_s + (1 - s)(1 - w)F_s - AL_m$	Not invest: $-AL_m - AF_g$

Dinamika replikator: $dx/dt = x(1 - x)[E(U_W|Safe) - E(U_W|Unsafe)]$, $dy/dt = y(1 - y)[E(U_S|Strict) - E(U_S|Lax)]$, $dz/dt = z(1 - z)[E(U_M|Invest) - E(U_M|Not\ invest)]$, dengan ekspektasi dihitung dari tabel payoff profil murni (Taylor dan Jonker, 1978). Sistem diselesaikan dengan RK4 ($\Delta t = 0{,}05$; $T = 50$). Stabilitas 8 titik ekuilibrium murni dinilai dengan metode Jacobian (Friedman, 1991): di titik sudut, Jacobian berbentuk diagonal dengan nilai eigen $\lambda_i = (1 - 2s_i)F_i$; titik merupakan ESS jika semua $\lambda_i < 0$. Kebenaran implementasi diuji dengan unit test (turunan numerik vs formula).

Parameter	**Arti**	**Nilai awal**
C_w, B_w	Biaya perilaku aman; manfaat perilaku tidak aman	2; 2
R_w, F_w, L_w	Insentif; penalti bila tertangkap; kerugian kecelakaan pekerja	1; 4; 10
C_s, R_s, F_s, L_s	Biaya pengawasan ketat; reward; penalti audit; kerugian akuntabilitas	2; 1; 3; 8
C_m, G, L_m, F_g	Biaya investasi; manfaat reputasi/regulasi; kerugian kecelakaan; denda pemerintah	3; 4; 30; 10
π, η	Peluang kecelakaan dari tindakan tidak aman; reduksi oleh investasi	0,2; 0,5
α_0, β_0	Peluang deteksi oleh supervisor ketat / longgar	0,6; 0,1
φ, r	Cakupan kamera; recall detektor (dari validasi)	0 (baseline) / 0,8; 0,8

Nilai di atas bersifat ilustratif (unit moneter ternormalisasi) dan wajib dijustifikasi dengan literatur atau survei ahli sebelum dilaporkan sebagai temuan.



Gambar 4. Hasil simulasi awal empat skenario (keluaran asli scripts/egt_figures.py).

Interpretasi awal (ilustratif): pada baseline tanpa teknologi, sistem bergerak ke E(0,1,1) - manajemen berinvestasi dan supervisor ketat, tetapi pekerja tetap tidak aman karena peluang terdeteksi terlalu rendah dibanding manfaat jalan pintas. Dengan pemantauan visual ($\varphi = 0{,}8$; $r = 0{,}8$) proporsi pekerja aman naik mendekati 1, namun supervisor cenderung beralih ke pengawasan longgar (efek substitusi teknologi / moral hazard). Detektor yang lemah ($r = 0{,}4$) dan penalti tinggi menghasilkan osilasi, ciri khas inspection game. Temuan ini memberi argumen kebijakan: sistem visi efektif hanya jika kualitas deteksinya memadai dan dibarengi audit terhadap supervisor.

9. Development Priority and Midterm Defense Target

Prioritas	Fitur	Status kode	Yang tersisa
P1 Core prototype	Web interface, upload, deteksi CV nyata, hasil deteksi, monitoring records	Selesai	Latih best.pt; siapkan video demo
P2 Research integration	Python processing, risk assessment, analytics, koneksi Phase 1	Selesai	Ganti data sintetis dengan data riil; validasi
P3 Further development	EGT terintegrasi	Selesai (versi awal)	Justifikasi parameter
P3 Further development	Kategori tambahan, real-time kamera, validasi lanjut	Belum	Setelah Midterm

Target per komponen untuk 21 November (sesuai komentar pembimbing):

Komponen	Target 21 November	Bukti yang akan ditunjukkan
Research framework	Jelas dan konsisten dengan Opening Report	Gambar 2; Bagian 3
Python analytics	Preliminary analysis yang benar-benar berjalan	Halaman Analytics dengan data riil (MSHA) + laporan kualitas data
EGT	Model awal atau hasil simulasi	Halaman EGT; Gambar 4; tabel stabilitas dan sensitivitas
Computer vision	Proof-of-concept minimal 1-2 kategori	NO_HELMET, NO_VEST (+ zona, proximity) pada video demo
Website	Preliminary web-based monitoring prototype	Demo langsung SafeMine Monitor
Integration	Minimal satu alur input → hasil deteksi di website	Upload → stream → event → risiko → dashboard
Validation	Pengujian awal, cocokkan dengan label aktual	mAP test split + event-level P/R/F1 pada video eksperimen

Fitur yang belum selesai disajikan sebagai ongoing development atau future work dan tidak diklaim berfungsi.

10. Expected Deliverables from the Development Team

No	Deliverable	Lokasi / status
1	System architecture diagram	docs/figures/architecture.png; Gambar 3
2	Website interface and preliminary UI	backend/static (9 halaman, tema gelap seperti contoh visualisasi)
3	Feature list and priorities	Bagian 5 dan 9
4	Proposed technologies and CV model	Bagian 8.1; training/train_yolo.py; train_colab.ipynb
5	Python and backend integration plan	Bagian 8.2; backend/app/main.py
6	EGT feasibility assessment	Bagian 8.3 dan 11 (Q3): layak, sudah diimplementasikan
7	Data requirements and sources	Bagian 7.2; data/*/README.md
8	Timeline sampai 19 November	Tabel 2 di bawah; detail di PDF Panduan Developer
9	Working prototype and demonstration	Folder SafeMine_Monitor + skrip demo
10	Source code and technical documentation	README.md, docs/risk_methodology.md, docstring tiap modul, tests/

Tanggal	Kegiatan
Jum 13 Nov (Hari 1)	Instalasi, jalankan web dengan model fallback, mulai training model APD di GPU cloud, rekam video eksperimen
Sab 14 Nov (Hari 2)	Pasang best.pt, proses video, unduh dan siapkan data MSHA, label ground truth
Min 15 Nov (Hari 3)	Validasi, gambar EGT final, screenshot, bekukan versi demo (backup)
16-17 Nov	Menulis bab metodologi dan hasil awal; slide presentasi
18 Nov	Gladi resik demo (offline), rencana cadangan
19 Nov	Demonstrasi internal
20 Nov	Perbaikan berdasarkan masukan
21 Nov	Midterm Defense

Tabel 2. Linimasa pengembangan.

11. Important Questions for the Team - Jawaban

Q1. Apakah tim dapat mengembangkan model CV yang benar-benar mampu mengidentifikasi unsafe behavior?

Ya, untuk kategori yang memiliki data berlabel. Detektor YOLO11 di-fine-tune pada dataset Construction Site Safety (mendukung helm dan rompi), lalu rule engine mengubah deteksi objek menjadi perilaku per pekerja dengan tracking dan filter temporal. Zona terlarang dan proximity berjalan bahkan dengan model COCO. Sebagai acuan, Tang (2021) melaporkan precision 79,78% dan recall 77,64% untuk pemeriksaan helm, dan Alotaibi dan Ma (2025) melaporkan F1 92,3% dengan arsitektur yang jauh lebih kompleks. Target realistis untuk prototipe: mAP@0,5 kelas APD sekitar 0,5-0,7 pada test split; angka sebenarnya harus diukur, bukan diasumsikan. Perilaku berbasis aksi (unsafe operation/movement) belum realistis untuk Midterm.

Q2. Apakah Python dapat diintegrasikan langsung dengan backend untuk memproses input dan menghasilkan detection results?

Ya, dan sudah diimplementasikan. Backend adalah FastAPI (Python), sehingga pipeline CV, analytics, dan EGT dipanggil langsung sebagai fungsi Python di thread pekerja latar belakang. Tidak ada perantara bahasa lain.

Q3. Apakah tim mampu mengembangkan EGT mathematical modeling and simulation?

Ya. Model tripartit sudah ditulis sebagai fungsi payoff eksplisit, persamaan replikator, integrasi RK4, analisis stabilitas Jacobian, dan analisis sensitivitas; semua dapat dijalankan dari website dan dari skrip untuk gambar tesis. Yang masih diperlukan adalah justifikasi nilai parameter (literatur/survei), yang merupakan pekerjaan riset, bukan pemrograman.

Q4. Bagaimana hasil Phase 1 dan Phase 2 dihubungkan dalam satu platform?

Melalui tiga jembatan pada Bagian 3.3: UBR dari sistem visi menjadi kondisi awal x_0; recall detektor dan cakupan kamera menjadi parameter deteksi EGT; statistik insiden Phase 1 menjadi dasar severity matriks risiko yang mengklasifikasikan event Phase 2. Ketiganya berada di satu database dan satu antarmuka.

Q5. Fitur apa yang realistis untuk demo 19 November?

Seluruh alur upload → deteksi (helm/rompi jika best.pt siap; zona dan proximity pasti) → stream replay dengan panel per pekerja → event bertimestamp → risiko dan rekomendasi → dashboard → analytics dengan data riil → simulasi EGT terkalibrasi → validasi pada 3-6 video eksperimen. Rencana cadangan: hasil diproses sebelumnya (batch_process.py) sehingga demo tetap jalan meski laptop lambat.

Q6. Apa yang masih perlu dikembangkan setelah Midterm?

Action recognition untuk unsafe operation dan movement; real-time webcam/RTSP; dataset tambang yang lebih representatif (debu, pencahayaan, alat berat besar); kalibrasi parameter EGT dengan survei ahli; validasi lebih luas dan uji antar-penilai; optimasi kecepatan (GPU, ONNX); pelaporan PDF otomatis; manajemen pengguna.

12. Keterbatasan dan Pernyataan Kejujuran Ilmiah

- Dataset publik didominasi konstruksi gedung; generalisasi ke tambang terbuka harus diuji dan dinyatakan sebagai keterbatasan.
- Proximity berbasis jarak 2D di citra, bukan jarak fisik; perspektif kamera memengaruhi hasil.
- Data sintetis di folder data/research hanya untuk menguji perangkat lunak dan diberi peringatan visual di website; tidak boleh dilaporkan.
- Parameter EGT ilustratif; kesimpulan kualitatif harus disertai analisis sensitivitas.
- Prototipe ini adalah alat penelitian, bukan sistem keselamatan tersertifikasi.

Referensi

Alotaibi, R. T. T., and Ma, S. (2025). Real-time detection of unsafe worker behaviors via adaptive vision transformers in construction sites. *Buildings*, 15(22), 4205. https://doi.org/10.3390/buildings15224205

Bonyaniakbarabadi, M. (2025). *AI-based object detection and risk identification for enhanced construction site safety* (Master's thesis). Louisiana State University.

Department of Occupational Safety and Health Malaysia. (2008). *Guidelines for hazard identification, risk assessment and risk control (HIRARC)*. JKKP DP 127/789/4-47.

Friedman, D. (1991). Evolutionary games in economics. *Econometrica*, 59(3), 637-666.

International Labour Organization. (2001). *Guidelines on occupational safety and health management systems (ILO-OSH 2001)*. Geneva: ILO.

International Labour Organization. (2018). *Code of practice on safety and health in opencast mines*. Geneva: ILO.

International Organization for Standardization. (2018). *ISO 45001:2018 Occupational health and safety management systems - Requirements with guidance for use*.

Jocher, G., and Qiu, J. (2024). *Ultralytics YOLO11* [Computer software]. https://github.com/ultralytics/ultralytics

Mine Safety and Health Administration. (2025). *Accident Injuries Data Set*. U.S. Department of Labor. https://www.msha.gov/mine-data-retrieval-system

Roboflow. Construction Site Safety dataset. Roboflow Universe (CC BY 4.0).

Tang, S. (2021). *Semantic and spatio-temporal understanding for computer vision driven worker safety inspection and risk analysis* (Doctoral dissertation). University of Illinois Urbana-Champaign.

Taylor, P. D., and Jonker, L. B. (1978). Evolutionary stable strategies and game dynamics. *Mathematical Biosciences*, 40(1-2), 145-156.

Zhang, Y., Sun, P., Jiang, Y., et al. (2022). ByteTrack: Multi-object tracking by associating every detection box. In *ECCV 2022*.